

Как машину научили читать

Часть 1 из 3 · от букв до языковых моделей

Кирилл Овчинников




**Через три часа вы будете понимать,
почему ваш агент ведёт себя именно так**

И сможете это чинить, а не удивляться.




Знакомое чувство



Спойлер: почти всегда второе. И это чинится.



Карта трёх часов



ОДИН РАЗ ОБЪЯСНЮ — ДАЛЬШЕ БУДУ ССЫЛАТЬСЯ

Первый час — фундамент. Дальше всё будет строиться на нём.



Три правила на сегодня

Перебивайте

Вопрос вслух в момент, когда он возник, полезнее вопроса в конце

Формул не будет

Ни одной, которую надо считать. Пара — просто чтобы показать, как выглядит

Глупых вопросов нет

Половина зала думает о том же, просто молчит



Поднимите руку

Кто пользовался ChatGPT или похожим на этой неделе?

А кто пробовал заставить его делать работу — и бросил, потому что получилось плохо?



БЛОК 1

Язык — самое сложное, что мы делаем не задумываясь

Прежде чем говорить про машину, посмотрим, с чем ей вообще пришлось иметь дело.



Казнить нельзя помиловать

одна и та же строка символов, два
противоположных решения



Виктор Перестукин подтверждает



«В стране невыученных уроков», 1969. Жизнь героя зависела от места запятой — которое выбирает читатель, а не буквы.

Та же беда в вашей переписке

«ЗАЯВКУ ЗАКРЫЛИ, КЛИЕНТ В КУРСЕ»

Кто закрыл? Клиент в курсе, что закрыли, — или в курсе проблемы?

«ОН СКАЗАЛ, ЧТО НЕ СМОЖЕТ ЕГО ПОДПИСАТЬ»

Кто «он», кто «его»? Двое мужчин в переписке — и всё, конец.



Смысл слова живёт не в слове

«Ключ»



потерял ключ от кабинета · ключ к решению · родник бьёт ключом · ключ шифрования

Одно слово, четыре несовместимых смысла. Выбирает — окружение.



Что вы делаете, читая одну фразу

Разбираете

на слова — хотя в речи
пауз между ними нет

Снимаете омонимию

выбираете один смысл
из четырёх

Достраиваете

«он», «там», «тогда» —
из памяти о разговоре

Считываете тон

«ну спасибо» — это не
благодарность

Всё это — за доли секунды и без всякого усилия.



А теперь то же самое — для программы

ЧТО ВИДИТ КОМПЬЮТЕР

Последовательность чисел. Не слова, не смысл, не тон. Числа, обозначающие символы.

1050 1083 1091 1073 32 1079 1072 1082 1088 1099 1090

Так выглядит фраза «Клуб закрыт» в памяти машины. Всё остальное надо построить с нуля.



1950: как понять, что машина «поняла»?

Алан Тьюринг

Вместо спора об определениях — практическая проверка.


Человек переписывается с двумя собеседниками. Один — человек, второй — машина.

Если он не может понять, кто есть кто, — спор о том, «думает» ли машина, теряет смысл.

Тьюринг задал планку не «понимать», а «быть неотличимым в разговоре». Через 72 года её взяли.



2025: тест сдают в обратную сторону



Семьдесят лет спустя уже мы доказываем машине, что мы не машина.



Задача звучала безнадёжно

Смысл не лежит в тексте. Он достраивается из контекста, памяти и знаний о мире.

А у машины есть только числа.




БЛОК 2

Три эпохи: как эту задачу пытались решить

Каждая эпоха дала рабочие продукты — и упёрлась в свою стену.



Семьдесят лет в одной картинке



Обратите внимание на расстояния: сорок лет, двадцать, семь, пять.



Эпоха первая: правила

Идея

Язык устроен по грамматике. Значит, наймём лингвистов, они запишут все правила, и машина по ним разберёт любую фразу.

Как выглядело

если существительное + в винительном
падеже → это дополнение

Тысячи таких строк, написанных руками.



Что было под маской



1954: первая демонстрация машинного перевода

ДЖОРДЖТАУНСКИЙ ЭКСПЕРИМЕНТ

Машина перевела 60 предложений с русского на английский. Публика в восторге. Авторы заявили: через три-пять лет перевод будет решён полностью.

ЧТО ОКАЗАЛОСЬ НА ДЕЛЕ

250 слов в словаре и 6 правил. Предложения были подобраны заранее. Полностью задача не решена и сегодня.




Как это выглядело



Машинный зал IBM. На такой машине — IBM 701 — и показали те самые 60 предложений.



Первый цикл хайпа — по учебнику



С тех пор эта кривая прокатилась по AI ещё минимум четыре раза. Узнавать её на глаз — часть управленческой гигиены.



1966: ELIZA — первый чат-бот

Программа изображала психотерапевта. Всё, что она делала, — переворачивала фразу собеседника в вопрос.

— Меня беспокоит моя работа.

— Расскажите подробнее, почему вас беспокоит ваша работа?

200 строк кода

Секретарь автора отказывалась разговаривать при нём — просила выйти из комнаты.



Почему правила упёрлись в стену

Исключений больше, чем правил

На каждое правило — сотня
«но не в этом случае»

Правила конфликтуют

Два верных правила дают два
разных разбора одной фразы


Не масштабируется

Новая тема, новый язык, новый
жаргон — писать всё заново
руками

К концу 1980-х системы разрослись до десятков тысяч правил, которые уже никто не мог поддерживать.



Рабочий день лингвиста, 1985



JAKE-CLARK.TUMBLR

Эпоха вторая: статистика

СМЕНА МЫШЛЕНИЯ

Перестать спрашивать «как правильно» и начать спрашивать «как **чаще**».

Машине дают гигантский корпус текстов и она считает: после «operating» чаще идёт «system», после «операционный» — «центр». Никто не объясняет ей грамматику.

Именно так заработали первые практически полезные переводчики и распознавание речи.



Смена эпох в одном меме



**спросить
лингвиста, как
правильно**



**посчитать, как
чаще**



Где сломалась статистика

ЧТО ПОЛУЧИЛОСЬ


- Работало без лингвистов
- Легко переносилось на новый язык
- Улучшалось, если дать больше текстов

ЧТО НЕ ПОЛУЧИЛОСЬ

- Помнила два-три слова назад
- Ни одного слова не «понимала»
- Незнакомое слово = ноль информации



Эпоха третья: нейросети



Разница принципиальная: раньше признаки задавал человек. Теперь модель находит их сама.



Дальше начинается механика

Три вопроса, на которые пришлось ответить, чтобы всё заработало:

как превратить текст в числа, как задать смысл слова, как научиться предсказывать.



БЛОК 3

Откуда взялись токены

Первый практический вопрос: на какие кусочки резать текст.



У машины нет букв. У неё есть номера

Значит, первое решение любой системы: **что считать одним кусочком** и какой номер ему дать.



Идея первая: пусть кусочек — это слово

Операционный

центр

закрыл

инцидент

Операционный

№ 4172

центр

№ 88

закрыл

№ 1206

инцидент

№ 9034

Составляем словарь всех слов языка, каждому даём номер. Логично. И не работает.



Проблема первая: русский язык

стол

стола

столу

столом

столе

столы

столов

столам

столами

столах

ДЕСЯТЬ НОМЕРОВ ВМЕСТО ОДНОГО

И для машины это десять **никак не связанных** слов. Она не знает, что это один стол.

Английскому проще: table, tables — и всё. Русскому, финскому, турецкому — катастрофа.



Боромир предупреждал



Проблема вторая: словарь всегда неполный

Опечатки

«инциднет» — слова нет в словаре, информации ноль

Новые слова

«ковид», «маркетплейс»,
название вашей системы

Ваш жаргон

«эскалация по второй линии»,
внутренние аббревиатуры

Всё, чего нет в словаре, превращается в одну заглушку «неизвестное слово». Фраза теряет ровно то, ради чего написана.



Проблема третья: пробелы есть не везде

Тайский

ฉันไปโรงเรียน

Ни одного пробела. Где здесь границы слов — отдельная нерешённая задача.

И даже у нас

«в течение» — одно слово или два?

«из-за», «по-моему», «нью-йоркский»?



Идея вторая: пусть кусочек — это буква

ЧТО ХОРОШО

- Словарь — 33 буквы, и он полный
- Опечатки не ломают
- Любое новое слово собирается

ЧТО ПЛОХО

- Фраза становится в 6–7 раз длиннее
- Буква «о» не несёт никакого смысла
- Модели приходится учить язык с нуля



Решение: кусочки между буквой и словом

Частые слова остаются целыми. Редкие разбираются на части, из которых собраны.



Как машина сама выбирает кусочки

Шаг 1

Начинаем с отдельных букв



Шаг 2

Находим самую частую пару соседей и склеиваем её в один кусок



Шаг 3

Повторяем 50 000 раз

Никто не пишет правила. Частотность сама решает, что склеить.



Что получается на русском

Операц

ионный

центр

закрыл

инцид

ент

The

operations

center

closed


the

incident

Та же фраза по-русски — вдвое больше кусочков, чем по-английски. Модели учились в основном на английском.



С этого момента и навсегда



Почему счета приходят в токенах

~0,75

английского слова в одном токене

~0,4

русского слова в одном токене

×2

во столько раз дороже русский текст

Токен — это и единица счёта, и единица памяти модели. Одно и то же число ограничивает и цену, и объём документа.



Что это значит для нас

ТРИ СЛЕДСТВИЯ

Модель видит не слова, а кусочки. Она может обработать незнакомое слово — соберёт его из частей.

Но опечатка меняет разбиение, и фраза для неё выглядит иначе.

ОТСЮДА ПРАКТИЧЕСКОЕ ПРАВИЛО

Аккуратный, единообразный текст на входе — не педантизм, а прямая экономия и рост качества.



БЛОК 4

Что такое «смысл» для машины

Кусочки мы получили. Но кусочек — это по-прежнему просто номер.



Номер в словаре не значит ничего

врач

№ 3141

доктор

№ 9877

таблица

№ 3142

«Врач» и «таблица» — соседние номера. «Врач» и «доктор» — на другом конце словаря.
Для машины близость номеров не значит **ничего**.



Каждое слово в своём ящике

врач = 0 0 0 1 0 0 0 0 0 0

доктор = 0 0 0 0 0 0 0 0 1 0

Так делали до 2013 года: вектор длиной во весь словарь, одна единица на своём месте.

Между любыми двумя словами — одинаковое расстояние. «Врач» так же далёк от «доктора», как от «экскаватора».



**«Слово узнаётся по компании, в которой
оно ходит»**

Джон Ферс, лингвист, 1957



Как понять незнакомое слово

«Вчера на смене вышел из строя тарлык, пришлось переключаться на резервный и вызывать инженера»

Вы не знаете этого слова. Но уже знаете: это оборудование, оно ломается, оно дублируется, его чинит инженер.

ОТКУДА ЗНАНИЕ

Не из слова. Из его окружения. Ровно этим и пользуется машина.



Машина делает то же самое — только миллиард раз

Берём слово

«инцидент»



Смотрим соседей во всех текстах

закрыть · критический · эскалация · дежурный · регистрация



Это и есть его портрет

слова с похожими соседями — похожи по смыслу



Слово как точка на карте смыслов

● врач
● доктор
● медсестра

● инцидент
● сбой
● авария

● экскаватор

Близко на карте = встречаются в похожем окружении. Расстояние стало измеримым.



Только карта не двумерная

2

измерения на слайде — чтобы было видно

300

измерений в первых моделях 2013 года

12 000+

измерений в современных

Представить 12 000 измерений нельзя, и не надо. Достаточно понимать: у каждого слова длинный список координат, и по ним считается расстояние.




И тогда обнаружилось странное



Никто не закладывал это специально. Отношения между словами сами превратились в направления на карте.



То же самое — стрелками на карте



«Сменить пол» — это одно и то же направление из любой точки карты. Таких направлений тысячи: время глагола, столица страны, множественное число.



Что это дало на практике

Поиск по смыслу

Запрос «не приходит письмо»
находит статью «проблемы с
доставкой почты»

Склейка дублей

Пять обращений про одно и то
же схлопываются в один
инцидент

Похожие случаи

«Что мы делали в прошлый раз
в такой же ситуации»

Всё это работает **без единого правила**, написанного человеком.



Смысл для машины — это положение на карте

Карту она построила сама, просто посчитав, кто с кем рядом стоит в миллиардах текстов.



БЛОК 5

Первая массовая задача: классификация

Короткий блок — но именно на нём NLP впервые начал приносить деньги.



Разложить текст по коробкам

Тональность

Отзыв положительный или отрицательный

Маршрутизация

В какую команду отдать обращение


Приоритет

Это критично или подождёт до понедельника


Одна и та же механика. Меняются только коробки.



Самый известный классификатор в мире



Как машина это решает



Никакого понимания. Голый подсчёт: «слово „не списалось“ в 90% случаев встречалось в коробке „биллинг“».



Почему метод назвали «наивным»

ЧТО ДЕЛАЕТ МАШИНА

Считает каждое слово **независимо** от остальных, как отдельный голос.


ПОЧЕМУ ЭТО НАИВНО

«Не работает» — это два слова, каждое со своим голосом. Смысл целого теряется.

Метод знал, что он неправ, — и всё равно работал достаточно хорошо, чтобы стать промышленным стандартом на двадцать лет.



Двадцать лет честного труда



Кстати, вы пользуетесь наивным Байесом с 2002 года: это он сортирует спам в вашей почте.



Где это ломалось

Отрицание

«Проблем не было» — слово
«проблема» голосует за жалобу

Ирония

«Ну спасибо, очень помогли»
— все слова положительные

Порядок

«Клиент подвёл нас» и «мы
подвели клиента» —
одинаковые слова

Всё это лечится одним: надо смотреть на слова **в связи друг с другом**, а не по одному.



Первые деньги NLP заработал на подсчёте слов

Но потолок был очевиден: пока слова считаются по отдельности, смысл фразы недоступен.



БЛОК 6

Языковая модель

Идея, из которой в итоге выросло всё, что вы сегодня используете.



Сначала — что такое «модель» вообще

Модель погоды

Не знает, что такое дождь. Считает вероятность: 70% осадков завтра.

Модель языка

Не знает, что такое смысл. Считает вероятность: какое слово идёт следующим.

Модель — это не копия реальности, а машинка для предсказаний о ней.



**Угадай
следующее
СЛОВО**

ВОТ И ВСЁ, ЧТО ДЕЛАЕТ ЯЗЫКОВАЯ МОДЕЛЬ



Вы пользуетесь этим двадцать лет

Добрый

день

вечер

человек

Подсказка над клавиатурой телефона — это языковая модель. Маленькая, но ровно та же идея.

Разница только в размере

Телефон помнит пару слов.
Современная модель —
сотни страниц.



Как это делали до нейросетей

Прочитать миллиард текстов и составить огромную таблицу: после каких двух слов какое третье встречалось чаще.

«операционный центр
...»



закрыл



сообщил



танцевал



Что получается, если так генерировать текст

«Операционный центр закрыл инцидент по данным на конец квартала составила двенадцать процентов годовых от суммы договора не подлежит возврату»

Каждая пара слов правдоподобна. Целое — бессмыслица.

ДИАГНОЗ

Модель помнит два слова назад. К концу предложения она забыла, о чём было начало.



Почему нельзя просто помнить больше слов



Таблица растёт быстрее, чем существует текстов на Земле. Большинство сочетаний не встретится **ни разу**.



Что было нужно

ТАБЛИЦА

Помнит только точные сочетания, которые
видела


НУЖНО ВМЕСТО НЕЁ

Что-то, что **обобщает**: видела «закрыл
инцидент» — справится и с «закрыл заявку»

Обобщение возможно, потому что «инцидент» и «заявка» рядом на карте смыслов из четвёртого блока.



Нейросеть, которая читает по одному слову



Читает слово, обновляет свою «краткосрочную память», передаёт дальше. Память — это уже не таблица, а набор чисел, который можно сжимать и обобщать.



И всё-таки она забывала

«Инцидент, о котором дежурная смена сообщила ещё в пятницу вечером, но который из-за праздников никто не разобрал, был наконец закрыт»

Чтобы поставить «был», надо помнить слово «инцидент» — а между ними четырнадцать слов.

Память — одна и та же коробка фиксированного размера. Чем длиннее текст, тем сильнее размывается начало.



Задача была найдена правильная

«Предсказать следующее слово» оказалось достаточно, чтобы выучить язык.

Не хватало только способа помнить далеко.



БЛОК 7

Где мы остановились к 2017 году

Что уже работало и что оставалось нерешённым.



Что к 2017 году уже работало

Текст → кусочки

Токены решили проблему словаря и новых слов

Кусочки → смысл

Карта смыслов дала обобщение и похожесть

Смысл → предсказание

Языковая модель научилась продолжать текст

Три кирпича, из которых собрано всё, что вы сегодня используете. Они не изменились.



И три нерешённые проблемы

Память

текст длиннее абзаца — начало теряется

Скорость

читает по одному слову, значит, обучение не ускорить

Ответы

модель продолжает текст, но не отвечает на вопрос





**И тут кто-то спросил: а что, если
просто сделать это очень большим?**

Не умнее. Не хитрее. Просто в тысячу раз больше.



Семьдесят лет эволюции — если честно

написать правила руками	
посчитать статистику	
обучить нейросеть	
просто сделать её в тысячу раз больше	



Что унести с собой из первого часа

ОДНА ФРАЗА

Модель не понимает текст. Она предсказывает следующий кусочек — очень хорошо.

ТРИ СЛЕДСТВИЯ, КОТОРЫЕ ПРИГОДЯТСЯ ВО ВТОРОМ ЧАСЕ

Всё, что она видит, — токены. Смысл для неё — это близость на карте.

Отвечать на вопросы она изначально не умела вообще.



Перерыв 10 минут

дальше — почему всё это внезапно заговорило по-человечески

